Universidad Yachay Tech

Maestría en Ciencia de Datos
Fundamentos de Inteligencia Artificial

Actividad 5

Clasificación supervisada mediante K-Nearest Neighbors

Selección de hiperparámetros y evaluación sobre Wine Recognition

Autor: Mat. Héctor Alexander Román Potosí

Octubre de 2026

Resumen

Se implementó un clasificador de aprendizaje supervisado basado en K-Nearest Neighbors (KNN) para identificar tres clases de vinos mediante trece características químicas.

Se emplearon 178 observaciones del conjunto Wine Recognition, una división estratificada del 80 % para entrenamiento y 20 % para prueba, y validación cruzada estratificada de cinco particiones.

La búsqueda de hiperparámetros evaluó valores de K entre 1 y 60. El mejor valor observado fue $K = 29$, con una exactitud media de validación de 97.88 %.

En la evaluación final se obtuvo una exactitud de 97.22 %, correspondiente a 35 predicciones correctas de 36.

Palabras clave: aprendizaje supervisado, KNN, clasificación multiclase, validación cruzada, selección de hiperparámetros.

1. Introducción

El aprendizaje supervisado permite construir modelos predictivos utilizando observaciones cuyas etiquetas son conocidas.

En problemas de clasificación, la variable objetivo pertenece a un conjunto discreto de categorías.

El algoritmo K-Nearest Neighbors clasifica una nueva observación utilizando las etiquetas de sus K vecinos más cercanos, de acuerdo con una medida de distancia.

El objetivo de este estudio es seleccionar y justificar el número de vecinos y evaluar el desempeño del clasificador sobre observaciones independientes del entrenamiento.

2. Fundamentos matemáticos

2.1. Representación de los datos

Se dispone de una matriz de características:

$$X \in \mathbb{R}^{178\times 13} \tag{1}$$

y un vector de etiquetas:

$$y \in \{0, 1, 2\}^{178}. \tag{2}$$

El problema consiste en construir una función:

$$f : \mathbb{R}^{13} \to \{0, 1, 2\}. \tag{3}$$

2.2. Estandarización

Debido a las diferencias de escala entre las características, se utiliza StandardScaler:

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}, \tag{4}$$

donde μ_j y σ_j representan, respectivamente, la media y la desviación estándar de la característica j calculadas sobre los datos de ajuste correspondientes.

2.3. Distancia euclidiana

La distancia entre dos observaciones estandarizadas es:

$$d(z_i, z) = \sqrt{\sum_{j=1}^{13} (z_{ij} - z_j)^2}. \tag{5}$$

2.4. Regla de clasificación

Sea $\mathcal{N}_K(z)$ el conjunto de los K vecinos más cercanos a la observación z.

La clase predicha se obtiene mediante votación:

$$\hat{y}(z) = \underset{c \in \{0,1,2\}}{\arg\max} \sum_{i \in \mathcal{N}_K(z)} \mathbf{1}(y_i = c). \tag{6}$$

3. Metodología

3.1. Conjunto de datos

Se utilizó Wine Recognition, disponible mediante Scikit-learn y procedente del repositorio UCI Machine Learning.

El conjunto contiene 178 observaciones, 13 características numéricas y tres clases.

Cuadro 1: Distribución de las clases

Clase	Observaciones	Porcentaje
0	59	33.15 %
1	71	39.89 %
2	48	26.97 %
Total	178	100 %

No se identificaron valores faltantes ni registros completamente duplicados.

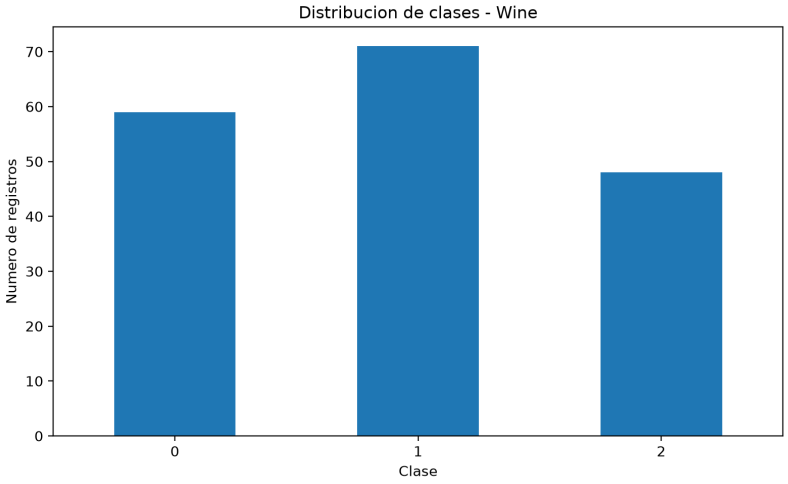


Figura 1: Distribución de las tres clases.

3.2. Análisis exploratorio

La representación de flavanoides e intensidad de color muestra regiones donde las clases se separan y otras donde se superponen.

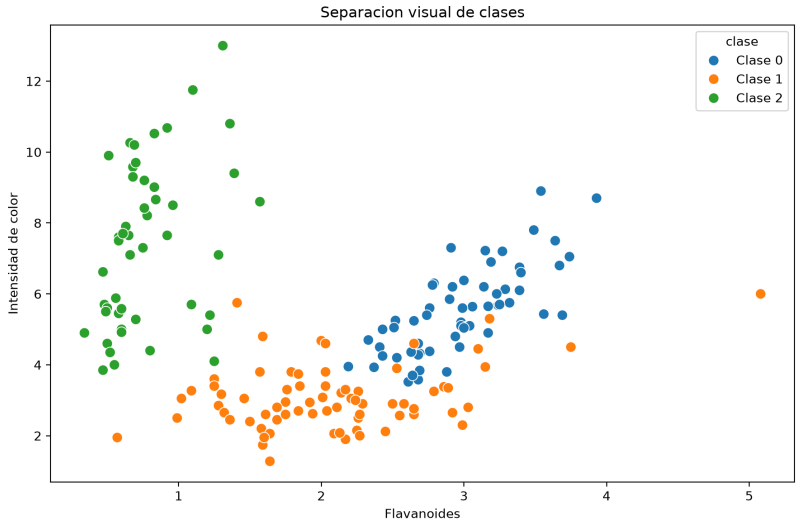


Figura 2: Separación visual de clases mediante dos características químicas.

3.3. División de datos

Se aplicó una división estratificada con `random_state=42`:

- Entrenamiento: 142 observaciones.
- Prueba: 36 observaciones.

El escalado se integró dentro de un Pipeline, evitando utilizar información del conjunto de prueba para ajustar las transformaciones.

3.4. Selección del hiperparámetro

Se examinaron valores:

$$K \in \{1, 2, \ldots, 60\}. \tag{7}$$

Para cada configuración se utilizó validación cruzada estratificada de cinco particiones.

El criterio de selección fue:

$$K^* = \arg\max_K \left(\frac{1}{5} \sum_{i=1}^{5} \text{Accuracy}_i(K) \right). \tag{8}$$

El conjunto de prueba permaneció reservado durante la selección del hiperparámetro.

4. Resultados

4.1. Optimización del número de vecinos

El mejor valor observado fue:

$$\boxed{K^* = 29} \tag{9}$$

con una exactitud promedio de validación cruzada de:

$$\overline{\text{Accuracy}}_{\text{CV}} = 0{,}978818. \tag{10}$$

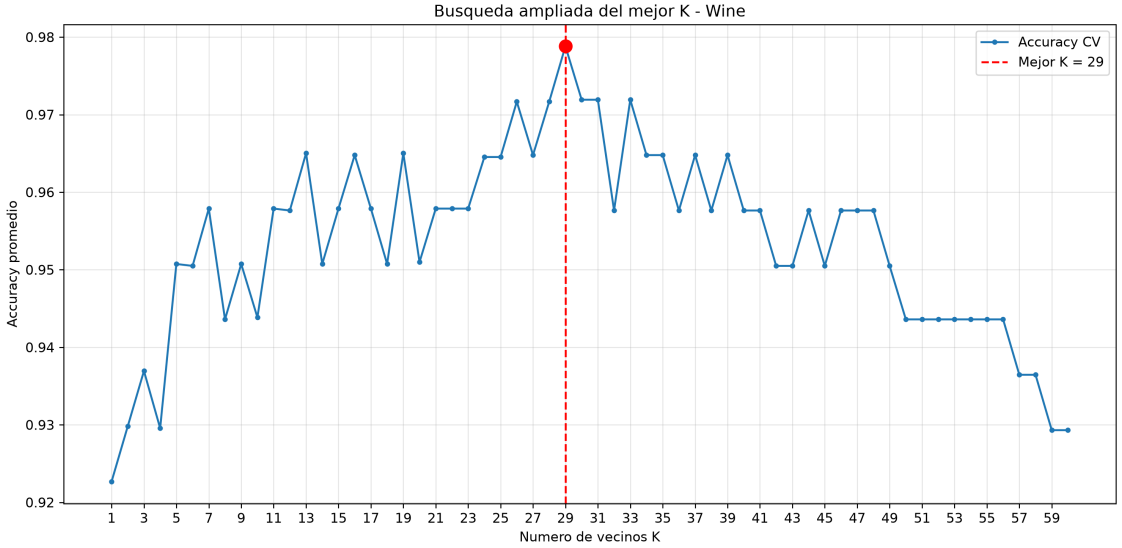


Figura 3: Búsqueda del mejor valor de K en el intervalo de 1 a 60.

4.2. Evaluación final

El modelo seleccionado se ajustó sobre las 142 observaciones de entrenamiento y se evaluó sobre las 36 observaciones de prueba.

Cuadro 2: Métricas de evaluación final

Métrica	Resultado
Accuracy	97.22 %
Balanced accuracy	97.62 %
Precision macro	97.44 %
Recall macro	97.62 %
F1-score macro	97.43 %

El clasificador acertó 35 observaciones y cometió un único error.

4.3. Matriz de confusión

La matriz de confusión obtenida fue:

$$C = \begin{pmatrix} 12 & 0 & 0 \\ 1 & 13 & 0 \\ 0 & 0 & 10 \end{pmatrix}. \tag{11}$$

Las filas representan las etiquetas reales y las columnas las predicciones.

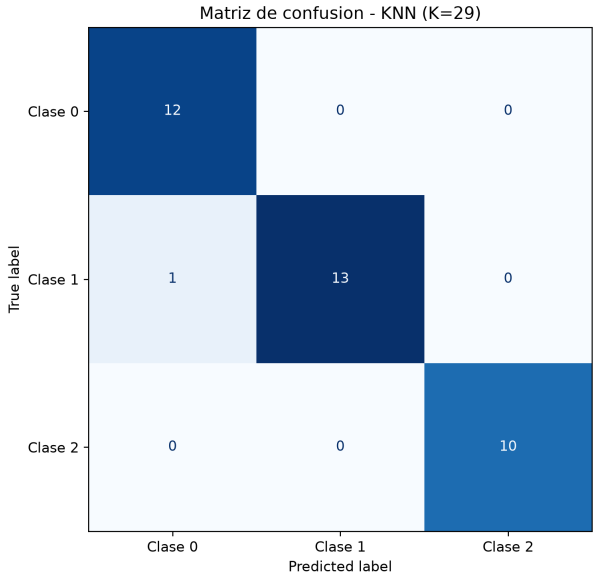


Figura 4: Matriz de confusión del clasificador final con $K = 29$.

El único error corresponde a una observación de clase 1 clasificada como clase 0.

4.4. Predicción demostrativa

Se utilizó una observación sintética con trece características químicas.

El modelo predijo la clase 0 y los 29 vecinos seleccionados votaron por dicha clase.

Este resultado demuestra la capacidad de inferencia del modelo, pero no representa una nueva evaluación, pues la etiqueta real es desconocida.

5. Discusión

El valor $K = 29$ presentó el mayor accuracy promedio dentro del conjunto de valores examinados.

La evaluación final obtuvo una exactitud de 97.22 %, cercana al resultado de validación cruzada de 97.88 %.

No obstante, el conjunto de prueba contiene únicamente 36 observaciones. Por ello, no puede afirmarse que el rendimiento observado esté garantizado sobre nuevas poblaciones de datos.

Además, la diferencia entre varios valores de K fue pequeña y podría variar con otras particiones de entrenamiento.

6. Conclusiones

El clasificador KNN permitió resolver satisfactoriamente un problema de clasificación supervisada multiclase.

La estandarización de las variables fue metodológicamente importante debido a sus diferentes escalas.

La validación cruzada permitió seleccionar $K = 29$ sin utilizar el conjunto de prueba para optimizar el hiperparámetro.

El desempeño final fue de 35 aciertos sobre 36 observaciones, equivalente a un accuracy de 97.22 %.

Se recomienda ampliar la evaluación en trabajos futuros con particiones adicionales y conjuntos independientes.

Referencias

[1] UCI Machine Learning Repository. *Wine Dataset*. https://archive.ics.uci.edu/dataset/109/wine.

[2] Scikit-learn. *Wine Recognition Dataset*. https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_wine.html.

[3] Scikit-learn. *KNeighborsClassifier*. https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.KNeighborsClassifier.html.